Теоретическое домашнее задание №2

Задача 1.

На занятиях мы не успели поговорить о том, как измерить качество модели в задаче классификации. Для этого есть множество интерпретируемых метрик, которые выражаются с помощью *confusion matrix*, в частности: *Accuracy, Precision, Recall, F1-score*; отдельно стоит *ROC-AUC*, который считается по семейству confusion matrix, построенных при всех возможных порогах.

Вам необходимо разобраться в понятиях, выделенных курсивом, выяснить, как они считаются, и дать содержательную интерпретацию. Подумайте, в каких задачах стоит выбирать ту или иную метрику.

Задача 2.

Пусть $b_1, \ldots, b_M$ — одинаково распределенные базовые алгоритмы, $a_M(x) = \frac{1}{M}\sum_m b_m(x)$, и в таком случае $\mathbb{E}b_i(x) = \mu$, $Var(b_i(x)) = \sigma^2$, $i = 1, \ldots, M$

(a) Покажите, что $\mathbb{E}\, a_M(x) = \mathbb{E}\, b_1(x)$. Какой вывод отсюда следует о выборе базовой модели для бэггинга?

(b) На занятиях мы пользовались тем фактом, что для $a_M(x)$ дисперсия равна

$$\mathrm{Var}(a_M(x)) = \rho\sigma^2 + \frac{1-\rho}{M}\sigma^2,$$

где σ^2 — дисперсия отдельного базового алгоритма, ρ — корреляция между различными парами базовых алгоритмов b. Как получается такая формула?

(c) Объясните с помощью пунктов (a)–(b), почему бэггинг применяют к глубоким деревьям, а не к линейной регрессии или к пням глубины 1. Что произойдет в формуле из (b), если базовые алгоритмы почти не различаются ($\rho \to 1$)?

Задача 3.

Убедитесь, что вы знаете ответы на следующие вопросы:

- Как устроен алгоритм построения решающего дерева?
- Что выдается в листе дерева в задаче классификации и в задаче регрессии?
- В чем идея бэггинга? Какие преимущества его применения?
- Как устроен алгоритм обучения случайного леса?
- Как kNN применяется в задаче регрессии? Как получить из kNN оценки вероятностей классов?
- Как гиперпараметр k влияет на сложность модели? Что происходит при $k = 1$ и при $k = n$ (где n — размер обучающей выборки)?
- Нужно ли масштабировать признаки для kNN? А для решающего дерева?
- В чем проявляется «проклятие размерности» применительно к kNN?